

# 1 GAN

## 1.1 GAN の Loss について

Discriminator の Loss は以下の通り.

$$\begin{aligned} & \mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z(\mathbf{z})} [\log (1 - D(G(\mathbf{z})))] \\ &= \mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{x} \sim p_g(\mathbf{x})} [\log (1 - D(\mathbf{x}))] \end{aligned} \quad (1)$$

ただし,  $\mathbf{x} \sim p_g(\mathbf{x})$  を  $\mathbf{x} = D(G(\mathbf{z})), \mathbf{z} \sim p_z(\mathbf{z})$  とした. また, Generator の Loss は以下の通り.

$$\mathbb{E}_{\mathbf{x} \sim p_g(\mathbf{x})} [\log (1 - D(\mathbf{x}))] \quad (2)$$

ここで,  $p_{data}(\mathbf{x}), p_g(\mathbf{x}), p_z(\mathbf{z})$  はそれぞれデータの生成分布と生成モデルからの出力分布, ノイズの分布を表す.

ただし, 式 (1), 式 (2) はデータの生成分布, 生成モデルからの出力分布で期待値を取っているが, 実際は以下の経験分布 (瀧 [1] p94 式 (5.2) 参照) を用いて近似的に汎化誤差を見積もった Loss を目的関数として最適化を行う.

$$\frac{1}{m} \sum_{i=1}^m [\log D(\mathbf{x}_i) + \log (1 - D(\mathbf{x}_i))] \quad (3)$$

$$\frac{1}{m} \sum_{i=1}^m \log (1 - D(G(\mathbf{z}_i))) \quad (4)$$

$m$  はデータ数を表す.

## 2 Loss の数学的解析

GAN は以下の価値関数で表される, Discriminator と Generator の two-player minmax game を行う.

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z(\mathbf{z})} [\log (1 - D(G(\mathbf{z})))] \quad (5)$$

この時, Generator が固定のもと,  $\max_D V(D, G)$  の最適値は

$$D_G^*(\mathbf{x}) = \frac{p_{data}(\mathbf{x})}{p_{data}(\mathbf{x}) + p_g(\mathbf{x})}$$

である.

*Proof.* GAN の評価関数より,

$$V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z(\mathbf{z})} [\log (1 - D(G(\mathbf{z})))] \quad (6)$$

$$= \int_{\mathbf{x}} p_{data}(\mathbf{x}) \log (D(\mathbf{x})) d\mathbf{x} + \int_{\mathbf{z}} p_z(\mathbf{z}) \log (1 - D(G(\mathbf{z}))) d\mathbf{z} \quad (7)$$

ここで,  $\mathbf{x} = G(\mathbf{z})$  では  $\mathbf{x} \sim p_g(\mathbf{x})$  なので

$$V(D, G) = \int_{\mathbf{x}} \{p_{data}(\mathbf{x}) \log D(\mathbf{x}) + p_g(\mathbf{x}) \log (1 - D(\mathbf{x}))\} d\mathbf{x} \quad (8)$$

さらに式 (8) において Discriminator の最適値とその時の Discriminator の値を考える.

$$\max_D V(D, G) = \max_D \int_{\mathbf{x}} \{p_{data}(\mathbf{x}) \log D(\mathbf{x}) + p_g(\mathbf{x}) \log (1 - D(\mathbf{x}))\} d\mathbf{x} \quad (9)$$

今, 積分範囲は  $\mathbf{x}$  が取りうるすべての値についてなので, 積分の中を最大にする  $D$  が最適値をとる時の Discriminator の値である. よって

$$\max_D p_{data}(\mathbf{x}) \log D(\mathbf{x}) + p_g(\mathbf{x}) \log (1 - D(\mathbf{x})) \quad (10)$$

を考える. また, 関数  $a \log x + b \log(1 - x)$  は

$$x = \frac{a}{a + b} \quad (11)$$

で最大値をとる. よって, 式 (9) において Discriminator の最適値を与える時のとる値  $D_G^*(\mathbf{x})$  は

$$D_G^*(\mathbf{x}) = \frac{p_{data}(\mathbf{x})}{p_{data}(\mathbf{x}) + p_g(\mathbf{x})} \quad (12)$$

である. またこの時の式 (7) の値 (最適値)  $C(G)$  は

$$C(G) = \max_D V(D, G) \quad (13)$$

$$= V(D_G^*, G) \quad (14)$$

$$= \mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})} [\log D_G^*(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z(\mathbf{z})} [\log (1 - D_G^*(G(\mathbf{z})))] \quad (15)$$

$$= \mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})} [\log D_G^*(\mathbf{x})] + \mathbb{E}_{\mathbf{x} \sim p_g(\mathbf{x})} [\log (1 - D_G^*(\mathbf{x}))] \quad (16)$$

$$= \mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})} \left[ \log \frac{p_{data}(\mathbf{x})}{p_{data}(\mathbf{x}) + p_g(\mathbf{x})} \right] + \mathbb{E}_{\mathbf{x} \sim p_g(\mathbf{x})} \left[ \log \left( 1 - \frac{p_{data}(\mathbf{x})}{p_{data}(\mathbf{x}) + p_g(\mathbf{x})} \right) \right] \quad (17)$$

$$= \mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})} \left[ \log \frac{p_{data}(\mathbf{x})}{p_{data}(\mathbf{x}) + p_g(\mathbf{x})} \right] + \mathbb{E}_{\mathbf{x} \sim p_g(\mathbf{x})} \left[ \log \frac{p_g(\mathbf{x})}{p_{data}(\mathbf{x}) + p_g(\mathbf{x})} \right] \quad (18)$$

□

## 参考文献

- [1] 瀧 雅人 「深層学習」 講談社
- [2] Ian Goodfellow, Generative Adversarial Networks  
<https://arxiv.org/abs/1406.2661>